Informe TP 06 — Clasificador Bayesiano

Detección de noticias falsas con Naive Bayes multinomial

1. Planteo del problema

Se aborda una tarea de **clasificación binaria de texto**: etiquetar un titular periodístico como **real** o **fake**. El corpus está compuesto por 10 titulares perfectamente balanceados (5 reales y 5 falsos).

2. Pipeline aplicado

- **Vectorización:** `CountVectorizer(lowercase=True)` — representa cada titular como un vector de conteo de palabras (*bag of words*). Paso obligatorio, ya que Naive Bayes no opera sobre texto crudo.
- **Modelo:** `MultinomialNB(alpha=1.0)` — variante de Naive Bayes adecuada para conteos de palabras, con suavizado de Laplace para que las palabras no vistas en una clase no anulen la probabilidad.
- **Validación:** `train_test_split(test_size=0.3, random_state=42, stratify=y)` → 7 titulares de entrenamiento y 3 de prueba (2 *fake*, 1 *real*), conservando la proporción de clases.

3. Resultados del modelo

0,6667	2 / 3	0,67
Precisión total (accuracy)	Aciertos sobre casos de prueba	F1-score (macro promedio)

Matriz de confusión

	pred. fake	pred. real
real: fake	1	1
real: real	0	1

Filas = clase real · Columnas = clase predicha. En verde los aciertos, en rojo el único error.

- 1 noticia **falsa** correctamente identificada como falsa.
- 1 noticia **falsa** clasificada erróneamente como real → **el único error del modelo**, y además el más costoso en este dominio: desinformación que atraviesa el filtro.
- 1 noticia **real** correctamente identificada como real.
- **0** noticias reales marcadas como falsas: el modelo no produjo falsas alarmas.

Reporte de clasificación

Clase	Precision	Recall	F1-score	Support
fake	1,00	0,50	0,67	2
real	0,50	1,00	0,67	1
macro avg	0,75	0,75	0,67	3
weighted avg	0,83	0,67	0,67	3

El patrón es claro y asimétrico: el modelo tiene **precision perfecta pero recall de 0,50 en la clase fake**. Es decir, cuando dice «falsa» acierta siempre, pero se le escapa la mitad de las falsas. De forma espejada, en la clase *real* obtiene recall 1,00 y precision 0,50: etiqueta como real todo lo real, pero también cosas que no lo son. En conjunto, el clasificador está **sesgado hacia declarar «real»** en los casos del conjunto de prueba.

4. Clasificación de noticias nuevas

Reentrenado con los 10 titulares completos, el modelo predice:

Titular	Predicción	P(fake)	P(real)
«Nuevo estudio demuestra que el café mejora la memoria»	fake	0,6136	0,3864
«Expertos afirman que los gatos pueden hablar con humanos»	fake	0,9510	0,0490

El segundo caso es un acierto nítido y con alta confianza (95 %): el titular comparte vocabulario característico de la clase *fake* del entrenamiento («afirman», «pueden»). El primero, en cambio, es discutible —un estudio sobre el café es plausiblemente una noticia real— y el modelo lo clasifica como falsa con una confianza baja (61 %). Esa probabilidad cercana al 50 % delata la causa: casi ninguna palabra de ese titular aparece en el vocabulario de entrenamiento, por lo que la decisión queda dominada por el suavizado de Laplace y las probabilidades a priori, no por evidencia léxica real.

5. Interpretación crítica

El accuracy de 0,6667 **no es estadísticamente confiable**. Con solo 3 casos de prueba, cada acierto o error desplaza la métrica 33 puntos porcentuales, y el intervalo de confianza resulta tan ancho que es compatible con un clasificador al azar. El resultado describe el comportamiento del procedimiento, no la capacidad de generalización del modelo.

La limitación de fondo es el **tamaño del corpus**: con 7 titulares de entrenamiento el vocabulario es diminuto y casi no se solapa con el del conjunto de prueba, de modo que el modelo decide con muy poca evidencia léxica.

Mejoras propuestas, en orden de impacto:

1. **Ampliar el corpus** a cientos o miles de titulares etiquetados. Es la restricción dominante; todo lo demás es secundario mientras no se resuelva.
2. **Reemplazar el split único por validación cruzada** (`cross_val_score` con *k-fold* estratificado) para estimar el desempeño con menor varianza y aprovechar todos los datos en la evaluación.
3. **Mejorar la representación del texto:** `TfidfVectorizer` para ponderar palabras discriminativas, eliminación de *stopwords* en español y n-gramas (1,2) para capturar expresiones compuestas como «estudio revela» o «científicos afirman», que son las que realmente marcan el estilo sensacionalista.

6. Conclusión

El trabajo implementa correctamente el flujo completo de un clasificador bayesiano de texto: vectorización, entrenamiento con suavizado, evaluación sobre datos no vistos y predicción de casos nuevos con sus probabilidades asociadas. El modelo alcanza un accuracy de 66,67 %, con un único error consistente en una noticia falsa clasificada como real, y muestra un sesgo hacia la clase *real*. Las métricas deben leerse como una demostración válida del procedimiento metodológico, no como una medida del desempeño alcanzable: para eso haría falta un conjunto de datos de un orden de magnitud mayor.