TP 07 — Clasificador bayesiano de mensajes de grooming

Procesamiento de Aprendizaje Automático · Equipo 8 · Informe de resultados del modelo

1. Objetivo y datos

El objetivo del trabajo es entrenar un clasificador de texto que distinga mensajes con indicios de **grooming** de mensajes cotidianos inofensivos (**No grooming**). El corpus es un conjunto propio y pequeño de **20 mensajes** en español, perfectamente balanceado: 10 ejemplos por clase. Son conversaciones cortas del tipo que un menor podría recibir por chat, donde los casos positivos combinan pedidos de fotos, preguntas sobre si está solo en casa y, sobre todo, la insistencia en el secreto («no le digas a nadie», «es nuestro secreto»).

2. Metodología

Como Naive Bayes no opera directamente sobre texto, el primer paso es vectorizar. Usamos `CountVectorizer` con `lowercase=True`, que construye una bolsa de palabras contando ocurrencias: los 20 mensajes quedan representados en un vocabulario de **93 términos** con 161 valores distintos de cero (una matriz muy dispersa, como es habitual en texto). Sobre esa representación entrenamos un **MultinomialNB** con `alpha=1.0`, es decir con suavizado de Laplace, que es la variante de Naive Bayes pensada para conteos de palabras y evita que una palabra no vista en una clase anule toda la probabilidad. La partición es **70 % entrenamiento / 30 % prueba**, estratificada por clase y con `random_state=42` para que el resultado sea reproducible: 14 mensajes para entrenar y 6 para evaluar.

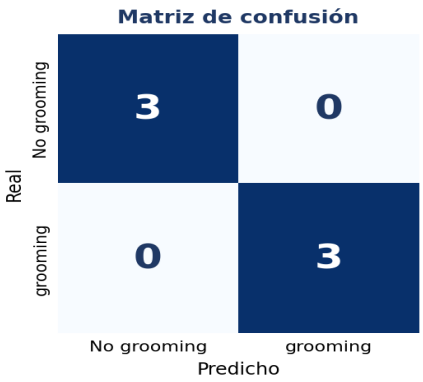
3. Resultados del modelo

Precisión total (accuracy): 1,0 — el modelo acertó los 6 mensajes del conjunto de prueba, sin ningún error.

Matriz de confusión (filas = real, columnas = predicho)

	No grooming	grooming
No grooming	3	0
grooming	0	3

Los 3 mensajes inofensivos y los 3 de grooming fueron clasificados en su clase correcta: cero falsos positivos y, lo más importante en esta aplicación, cero falsos negativos.



Reporte de clasificación

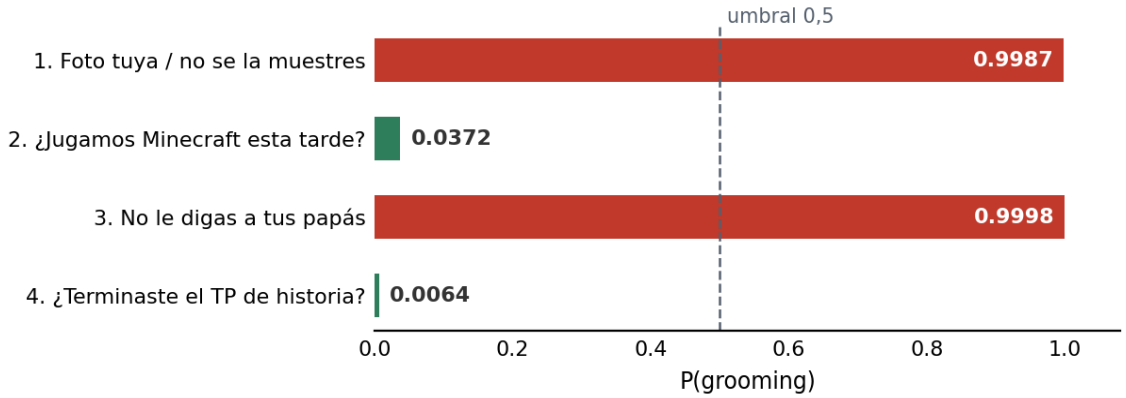
Clase	precision	recall	f1-score	support
No grooming	1,00	1,00	1,00	3
grooming	1,00	1,00	1,00	3
accuracy			**1,00**	**6**
macro avg	1,00	1,00	1,00	6
weighted avg	1,00	1,00	1,00	6

Las tres métricas valen 1,00 en ambas clases. El *recall* de la clase grooming es el número que más nos interesa —mide qué proporción de los mensajes peligrosos reales fueron detectados— y aquí es perfecto, aunque sobre una base de solo 3 casos.

4. Clasificación de los nuevos mensajes

Para predecir sobre mensajes nuevos el modelo se reentrena con los 20 ejemplos completos y luego se le pasan cuatro frases que no formaban parte de la evaluación. Junto con la etiqueta se muestran las probabilidades a posteriori de cada clase.

#	Mensaje	Predicción	P(No grooming)	P(grooming)
1	“¿Podés mandarme una foto tuya? No se la muestres a nadie.”	grooming	0,0013	0,9987
2	“¿Jugamos Minecraft esta tarde?”	No grooming	0,9628	0,0372
3	“No le digas a tus papás que hablamos, ¿sí?”	grooming	0,0002	0,9998
4	“¿Terminaste el trabajo práctico de historia?”	No grooming	0,9936	0,0064



Probabilidad asignada a la clase *grooming* en cada mensaje nuevo.

Las cuatro predicciones coinciden con la etiqueta esperada y, además, el modelo decide con mucha confianza: los dos casos de grooming superan el 0,998 y los inofensivos quedan por debajo de 0,04. Los mensajes 1 y 3 contienen justamente las expresiones de secreto y el pedido de fotos que dominan la clase positiva en el entrenamiento; los mensajes 2 y 4 se apoyan en vocabulario escolar y de juegos.

5. Interpretación y limitaciones

El resultado es muy bueno en apariencia, pero como estudiante de ciencia de datos hay que leerlo con cautela: un accuracy de 1,0 medido sobre **6 mensajes** no es evidencia sólida de que el modelo generalice. Cada acierto o error mueve la métrica un 16,7 %, así que el margen de error real es enorme. Tres puntos a tener presentes:

Limitación	Detalle
Corpus mínimo	20 mensajes y 93 términos de vocabulario. El modelo aprende palabras concretas, no el concepto de grooming; cualquier frase con sinónimos nuevos («mandá una selfie», «que quede entre nosotros») cae fuera de lo visto.
Fuga en el mensaje 2	“¿Jugamos Minecraft esta tarde?” es idéntico a un ejemplo del entrenamiento, por lo que su 0,9628 no es una predicción genuina sobre texto nuevo.

Separación demasiado limpia	Los ejemplos de cada clase usan vocabulario casi disjunto, lo que vuelve el problema trivialmente separable. En chats reales las dos clases comparten muchísimas palabras y el modelo tendría errores.

Mejoras propuestas. Ampliar el corpus a varios cientos de mensajes y con mayor variedad léxica; validar con *k-fold cross-validation* en lugar de una única partición de 6 casos, para obtener una media y un desvío de las métricas; incorporar n-gramas (bigramas como «no le digas») y eliminar stopwords para enriquecer los atributos; y, dado el costo asimétrico del error, priorizar el *recall* de la clase grooming moviendo el umbral de decisión por debajo de 0,5, ya que dejar pasar un mensaje peligroso es mucho más grave que marcar de más uno inofensivo.

6. Conclusión

El clasificador `CountVectorizer + MultinomialNB` resuelve correctamente la tarea planteada: acierta el 100 % del conjunto de prueba y clasifica bien los cuatro mensajes nuevos con probabilidades muy marcadas. Queda demostrado que Naive Bayes multinomial es una técnica adecuada y muy económica para detección de texto, pero las métricas perfectas son consecuencia del tamaño y la limpieza del dataset y no deben interpretarse como rendimiento esperable en producción.