# TP 08 – Segmentación de jurisdicciones argentinas por viviendas habitadas

*Procesamiento de Aprendizaje Automático – Equipo 8 – Informe de resultados del modelo K-Means*

## 1. Objetivo y datos

El objetivo es agrupar las 24 jurisdicciones de la Argentina en tres segmentos —**muchas viviendas**, **cantidad normal de viviendas** y **pocas viviendas**— según el total de viviendas particulares habitadas registradas por el INDEC en el Censo 2022. A diferencia de los trabajos anteriores (árbol de decisión, clasificador bayesiano), aquí no hay una etiqueta conocida de antemano: es un problema de **aprendizaje no supervisado**, donde el algoritmo descubre los grupos por sí mismo y nuestro trabajo es interpretarlos y ponerles nombre.

Los datos están cargados en el propio programa como un diccionario `jurisdicción: viviendas` y se vuelcan luego a un DataFrame de pandas para mostrar los resultados. Antes de agrupar conviene mirar cómo se distribuye la variable, porque eso condiciona todo lo que sigue:

| Medida | Valor | Lectura |
|---|---|---|
| Cantidad de jurisdicciones | 24 | Las 23 provincias más CABA |
| Total de viviendas | 15.699.016 | Suma de todo el país |
| Media | 654.126 | Muy por encima de la mediana |
| Mediana | 293.866 | La mitad de las provincias está por debajo |
| Desvío estándar | 1.195.804 | Casi el doble de la media |
| Mínimo | 65.535 | Tierra del Fuego |
| Máximo | 5.970.702 | Buenos Aires: el 38 % del total del país |

El dato clave es que la media (654.126) más que duplica a la mediana (293.866) y el desvío supera a la media. La distribución está fuertemente **sesgada a la derecha**: unas pocas jurisdicciones enormes conviven con muchas muy chicas. Solo Buenos Aires concentra el 38 % de las viviendas del país, y entre Buenos Aires, CABA, Córdoba y Santa Fe suman el 63,8 %. Esta asimetría va a explicar casi todo el resultado del agrupamiento.

## 2. Metodología

**Preparación.** K-Means espera una matriz de forma (n_muestras, n_características), así que los 24 valores del diccionario se convierten en una columna con `reshape(-1, 1)`. **No estandarizamos los datos**, y es una decisión deliberada: al trabajar con una única variable, dividir por el desvío reescala todas las distancias por el mismo factor y no cambia en absoluto qué punto cae en qué grupo. Estandarizar sí será imprescindible en la actividad b), donde conviven edad, horas de estudio y promedio, que se miden en escalas distintas.

**El algoritmo.** K-Means parte de 3 centroides iniciales (con *k-means*++, que los elige separados entre sí) y repite dos pasos hasta que dejan de moverse: asignar cada jurisdicción al centroide más cercano y recalcular cada centroide como el promedio de los puntos que le tocaron. Lo que minimiza es la **inercia**, es decir la suma de las distancias al cuadrado de cada punto a su centroide.

**Parámetros usados.** `KMeans(n_clusters=3, n_init=10, random_state=42)`. Con `n_init=10` el algoritmo se corre diez veces con inicializaciones distintas y se queda con la de menor inercia, para no depender de un arranque desafortunado; `random_state=42` fija la semilla para que el resultado sea siempre el mismo.

**Etiquetado interpretable.** K-Means numera los clusters de manera arbitraria (0, 1, 2) y ese número no dice nada sobre el tamaño del grupo. Por eso el programa ordena los centroides de menor a mayor con

`argsort` y recién entonces asigna los nombres por posición: el centroide más bajo recibe «Pocas viviendas», el del medio «Cantidad normal de viviendas» y el más alto «Muchas viviendas». Así la etiqueta siempre significa lo mismo, sin importar cómo numeró scikit-learn los grupos.

## 3. Resultados: los tres segmentos

El modelo converge a estos tres grupos:

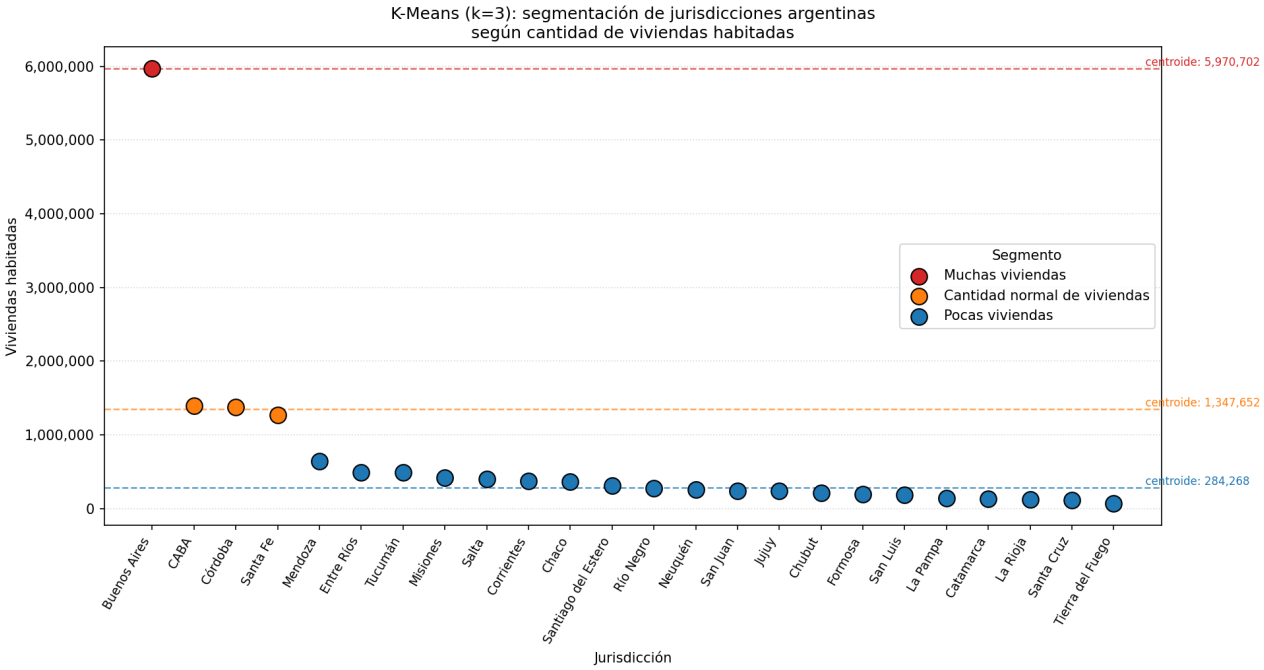
| Segmento | Centroide | Jurisdicciones | Rango del grupo |
|---|---|---|---|
| Muchas viviendas | 5.970.702 | 1 | — (un solo caso) |
| Cantidad normal de viviendas | 1.347.652 | 3 | 1.273.460 – 1.391.258 |
| Pocas viviendas | 284.268 | 20 | 65.535 – 639.467 |

Las fronteras entre segmentos quedan en el punto medio entre centroides vecinos: una jurisdicción pasa de «pocas» a «normal» al superar las **815.960** viviendas, y de «normal» a «muchas» al superar las **3.659.177**. El detalle completo, ordenado de mayor a menor, es el siguiente:

| Jurisdicción | Viviendas habitadas | Segmento |
|---|---|---|
| Buenos Aires | 5.970.702 | Muchas viviendas |
| CABA | 1.391.258 | Cantidad normal de viviendas |
| Córdoba | 1.378.237 | Cantidad normal de viviendas |
| Santa Fe | 1.273.460 | Cantidad normal de viviendas |
| Mendoza | 639.467 | Pocas viviendas |
| Entre Ríos | 494.473 | Pocas viviendas |
| Tucumán | 493.794 | Pocas viviendas |
| Misiones | 420.101 | Pocas viviendas |
| Salta | 404.504 | Pocas viviendas |
| Corrientes | 370.958 | Pocas viviendas |
| Chaco | 368.728 | Pocas viviendas |
| Santiago del Estero | 311.361 | Pocas viviendas |
| Río Negro | 276.371 | Pocas viviendas |
| Neuquén | 254.545 | Pocas viviendas |
| San Juan | 241.436 | Pocas viviendas |
| Jujuy | 238.141 | Pocas viviendas |
| Chubut | 213.317 | Pocas viviendas |
| Formosa | 194.689 | Pocas viviendas |
| San Luis | 182.886 | Pocas viviendas |
| La Pampa | 140.879 | Pocas viviendas |
| Catamarca | 131.978 | Pocas viviendas |
| La Rioja | 124.149 | Pocas viviendas |
| Santa Cruz | 118.047 | Pocas viviendas |
| Tierra del Fuego | 65.535 | Pocas viviendas |

## 4. Gráfico de dispersión

El programa grafica cada jurisdicción como un punto: en el eje horizontal están ordenadas de mayor a menor y en el vertical la cantidad de viviendas habitadas. El color indica el segmento asignado y las líneas punteadas marcan el centroide de cada cluster.




*Segmentación obtenida con K-Means (k = 3). Cada punto es una jurisdicción; las líneas punteadas son los centroides.*

El gráfico muestra con claridad por qué el algoritmo partió los datos donde los partió: Buenos Aires queda aislada arriba de todo, con más de cuatro veces las viviendas del segundo puesto; debajo aparece un pequeño pelotón de tres jurisdicciones muy parecidas entre sí (CABA, Córdoba y Santa Fe, las tres en torno a 1,3 millón); y finalmente una larga cola de 20 jurisdicciones apretadas contra el eje. Los dos huecos visibles del gráfico —entre Buenos Aires y CABA, y entre Santa Fe y Mendoza— son exactamente los cortes que eligió K-Means.

## 5. Calidad del agrupamiento

Para no quedarnos solo con la impresión visual medimos el agrupamiento con dos indicadores. La **inercia** (443.994.113.530 para k = 3) mide qué tan compactos son los grupos, pero siempre baja al agregar clusters, así que se usa buscando el «codo». El **coeficiente de silueta** va de –1 a 1 y compara, para cada punto, qué tan cerca está de su grupo frente a qué tan lejos está del grupo vecino. Probamos varios valores de k:

| k | Inercia | Silueta | Tamaños de los grupos |
|---|---|---|---|
| 2 | 3.393.867.841.021 | 0,8887 | 23 – 1 |
| **3** | **443.994.113.530** | **0,8045** | **20 – 3 – 1** |
| 4 | 126.375.858.649 | 0,6307 | 13 – 7 – 3 – 1 |
| 5 | 76.622.203.807 | 0,5698 | 12 – 5 – 3 – 3 – 1 |
| 6 | 39.608.530.448 | 0,5902 | 7 – 5 – 5 – 3 – 3 – 1 |

Con k = 3 la silueta global es **0,8045**, un valor alto, y la inercia cae un 87 % respecto de k = 2. Mirando grupo por grupo, sin embargo, el número se desarma: el segmento «normal» tiene silueta 0,9249 y el de «pocas» 0,8267, pero el de «muchas viviendas» tiene **silueta 0,0000**, porque un cluster de un solo elemento no tiene distancia interna que medir. En otras palabras, buena parte del 0,80 se lo debemos a lo fácil que es aislar a Buenos Aires, no a que los otros dos grupos sean especialmente informativos.

## 6. Interpretación y limitaciones

El resultado es correcto desde lo matemático —K-Means minimizó la inercia y los nombres de los segmentos se corresponden con el orden de los centroides—, pero como segmentación útil tiene

problemas que conviene señalar:

| Limitación | Detalle |
|---|---|
| Buenos Aires domina el modelo | Con 5.970.702 viviendas (el 38 % del país) es un valor atípico que se lleva un cluster entero para sí. El segmento «muchas viviendas» termina describiendo a una sola jurisdicción, y K-Means, que trabaja con medias, es muy sensible a este tipo de extremos. |
| El grupo «pocas» es demasiado heterogéneo | Reúne 20 de las 24 jurisdicciones (el 83 %) en un rango que va de 65.535 a 639.467: Mendoza tiene casi diez veces las viviendas de Tierra del Fuego y las dos quedan etiquetadas igual. Un segmento que contiene a casi todo el país informa poco. |
| La silueta alta es engañosa | El 0,8045 global convive con una silueta de 0,0000 en el cluster de Buenos Aires. La métrica premia la separación del atípico, no la calidad de la partición. |
| Una sola variable, y en valores absolutos | Se mide tamaño total, no densidad ni calidad habitacional. Una provincia con muchas viviendas simplemente tiene mucha población: el agrupamiento termina siendo un ranking de tamaño disfrazado de segmentación. |

**Mejoras propuestas.** La más directa es corregir la asimetría aplicando una transformación logarítmica antes de agrupar. Al correr K-Means sobre `log10(viviendas)` la partición se vuelve mucho más equilibrada y más parecida a lo que uno esperaría de una segmentación:

| Segmento (con log10) | N | Rango | Jurisdicciones |
|---|---|---|---|
| Muchas viviendas | 4 | 1.273.460 – 5.970.702 | Buenos Aires, CABA, Córdoba, Santa Fe |
| Cantidad normal | 12 | 238.141 – 639.467 | Mendoza, Entre Ríos, Tucumán, Misiones, Salta, Corrientes, Chaco, Santiago del Estero, Río Negro, Neuquén, San Juan, Jujuy |
| Pocas viviendas | 8 | 65.535 – 213.317 | Chubut, Formosa, San Luis, La Pampa, Catamarca, La Rioja, Santa Cruz, Tierra del Fuego |

Otras líneas de mejora: **relativizar la variable** (viviendas por habitante o por kilómetro cuadrado) para que el agrupamiento deje de ser un ranking de tamaño; **sumar atributos** como el porcentaje de viviendas desocupadas o el tipo de vivienda, lo que permitiría una segmentación realmente multivariada; **elegir k con criterio**, comparando codo y silueta en lugar de fijarlo de entrada; y tener presente que K-Means asume grupos esféricos y de tamaño similar, supuesto que estos datos claramente no cumplen —un método jerárquico o basado en densidad trataría mejor a los atípicos.

## 7. Conclusión

El programa cumple los cinco puntos de la consigna: carga los datos, aplica K-Means con 3 clusters, les asigna etiquetas interpretables ordenando los centroides, muestra el segmento de cada una de las 24 jurisdicciones y visualiza el resultado en un gráfico de dispersión. El modelo separa al país en Buenos Aires por un lado, el trío CABA–Córdoba–Santa Fe por otro, y las 20 jurisdicciones restantes en un tercer grupo.

La conclusión más valiosa del trabajo, sin embargo, es metodológica: una métrica alta no garantiza una segmentación útil. La silueta de 0,80 parece excelente, pero esconde un cluster de un solo elemento y otro que agrupa al 83 % del país. Cuando la variable está tan sesgada como esta, la preparación de los datos —transformar, relativizar, elegir bien los atributos— define el resultado tanto o más que el algoritmo elegido.