TP 09 - Segmentación de estudiantes universitarios con K-Means

Procesamiento de Aprendizaje Automático - Equipo 8 - Informe de resultados del modelo K-Means aplicado a un set simulado de 50 estudiantes

1. Objetivo y datos

El objetivo es agrupar a 50 estudiantes universitarios en **cuatro segmentos** según tres características: la **edad**, las **horas de estudio semanales** y el **promedio académico**. Como en el TP 08, se trata de un problema de **aprendizaje no supervisado**: no existe una etiqueta conocida de antemano que diga a qué grupo pertenece cada estudiante, sino que el algoritmo descubre los grupos por sí mismo y nuestro trabajo es interpretarlos y ponerles nombre. La diferencia con el trabajo anterior es que ahora conviven tres variables medidas en escalas distintas, y eso obliga a estandarizar los datos antes de agrupar.

Los datos son simulados y están cargados en el propio programa como una lista de diccionarios, que luego se vuelca a un DataFrame de pandas. Antes de agrupar conviene mirar cómo se distribuye cada variable, porque de ahí sale la justificación del primer paso del procesamiento:

Variable	Mínimo	Media	Mediana	Máximo	Desvío estándar	Rango
Edad (años)	21,00	39,54	39,50	60,00	11,13	39,00
Horas de estudio semanales	2,00	7,86	7,00	15,00	3,84	13,00
Promedio académico	1,00	5,52	6,00	9,11	2,53	8,11

Las tres variables se mueven en órdenes de magnitud muy distintos: la edad abarca 39 años de rango con un desvío de 11,13, mientras que el promedio académico se mueve entre 1 y 9,11 con un desvío de 2,53. Esa diferencia de escala es, como se verá, el problema principal a resolver antes de aplicar el algoritmo.

También conviene mirar cómo se relacionan las variables entre sí:

Correlación de Pearson	Edad	Horas de estudio	Promedio académico
Edad	1,000	-0,924	0,708
Horas de estudio	-0,924	1,000	-0,731
Promedio académico	0,708	-0,731	1,000

Hay dos relaciones muy fuertes. La primera es que la edad y las horas de estudio están casi perfectamente enfrentadas (**-0,924**): en este set, cuanto más grande es el estudiante, menos horas dedica al estudio. La segunda es llamativa y conviene señalarla desde el principio: la correlación entre horas de estudio y promedio es **-0,731**, es decir que en estos datos **estudiar más horas se asocia a un promedio más bajo**, al revés de lo que uno esperaría. Esto no es un error del algoritmo sino una característica del set simulado, y condiciona por completo la lectura de los segmentos que aparecen más adelante.

2. Cómo funciona el algoritmo K-Means

K-Means es un algoritmo de agrupamiento **particional**: divide el conjunto de datos en un número **k** de grupos fijado de antemano, de modo que cada observación pertenece a exactamente un grupo. Cada grupo queda representado por su **centroide**, que es el punto promedio de todos los elementos que le fueron asignados. En nuestro caso cada estudiante es un punto en un espacio de tres dimensiones (edad, horas, promedio) y k = 4 por consigna.

El procedimiento repite dos pasos hasta que los centroides dejan de moverse:

Paso	Qué hace
0. Inicialización	Elige k puntos iniciales como centroides. scikit-learn usa por defecto *k-means++*, que los elige bien separados entre sí para evitar arranques desafortunados.
1. Asignación	Calcula la distancia euclídea de cada estudiante a los k centroides y lo asigna al más cercano. Aquí es donde la escala de cada variable define el resultado.
2. Actualización	Recalcula cada centroide como el promedio de los puntos que le tocaron en el paso anterior.
3. Convergencia	Repite 1 y 2 hasta que las asignaciones no cambian o se alcanza el máximo de iteraciones. En este trabajo el modelo convergió en **13 iteraciones**.

Lo que el algoritmo minimiza se llama **inercia** (o suma de cuadrados intra-cluster): la suma de las distancias al cuadrado de cada punto al centroide de su grupo. Cuanto menor es la inercia, más compactos son los grupos. K-Means no garantiza encontrar el mínimo global de esa función -depende de los centroides iniciales-, por eso se corre varias veces y se conserva la mejor solución.

Tres propiedades del algoritmo son importantes para este trabajo y se retoman en las conclusiones: **(a)** el valor de k debe elegirse de antemano, el algoritmo no lo descubre; **(b)** trabaja con promedios y distancias euclídeas, por lo que supone grupos de forma más o menos esférica y de tamaños parecidos; **(c)** es **sensible a la escala** de las variables, que es exactamente el problema que resuelve la estandarización.

3. Metodología aplicada

Estandarización (punto 1 de la consigna). Como K-Means asigna cada punto por distancia euclídea, una variable con números más grandes pesa más que las demás solamente por su escala. El peso real de cada variable en la distancia es proporcional a su varianza, y en este set el reparto es muy desparejo:

Variable	Varianza	Peso en la distancia sin estandarizar
Edad	121,49	85,4 %
Horas de estudio	14,48	10,2 %
Promedio académico	6,25	4,4 %

Sin estandarizar, la edad se lleva el **85,4 %** del peso y el promedio académico apenas el **4,4 %**: el agrupamiento sería, en los hechos, una partición por edad. Para comprobarlo corrimos también K-Means sobre los datos crudos, y el resultado son cuatro franjas etarias consecutivas que ignoran el rendimiento:

Grupo sin estandarizar	N	Rango de edad	Rango de horas	Rango de promedio
Grupo 1	12	21 a 29	8 a 15	1,00 a 9,11
Grupo 2	12	30 a 38	7 a 11	2,00 a 5,00
Grupo 3	13	39 a 48	2 a 8	5,00 a 8,87
Grupo 4	13	49 a 60	2 a 5	6,12 a 9,00

El primer grupo mezcla promedios de 1,00 a 9,11 en un mismo segmento: la variable que más nos interesa quedó completamente diluida. La coincidencia entre esa partición y la que obtenemos con datos estandarizados, medida con el índice de Rand ajustado, es de apenas **0,415** (1 sería coincidencia total), lo que confirma que estandarizar no es un detalle sino que cambia el resultado por completo.

La solución es `StandardScaler` de scikit-learn, que transforma cada variable en **z = (x - media) / desvío**. Después de la transformación las tres variables tienen media 0 y desvío 1, por lo que pesan lo mismo en la distancia y el valor de cada coordenada pasa a leerse como «cuántos desvíos estándar por encima o por debajo del promedio general». Los parámetros que aprendió el escalador sobre estos datos son:

Variable	Media original	Desvío original	Media escalada	Desvío escalado
Edad	39,540	11,022	0,000	1,000
Horas de estudio	7,860	3,805	0,000	1,000
Promedio académico	5,518	2,500	0,000	1,000

Parámetros del modelo. Se usó `KMeans(n_clusters=4, n_init=10, random_state=42)`. Con `n_init=10` el algoritmo se corre diez veces con inicializaciones distintas y se queda con la de menor inercia, para no depender de un arranque desafortunado; `random_state=42` fija la semilla para que el resultado sea siempre el mismo. El modelo se entrena sobre los datos **ya estandarizados**, y los centroides se devuelven a las unidades originales con `inverse_transform` solamente para poder interpretarlos.

Etiquetado interpretable. K-Means numera los clusters de manera arbitraria (0, 1, 2, 3) y ese número no dice nada sobre el perfil del grupo. Por eso el programa arma el nombre de cada segmento leyendo su centroide estandarizado: si una coordenada está más de medio desvío por encima de la media general el nivel es «alto», si está más de medio desvío por debajo es «bajo», y entre ambos umbrales es «medio». Con esos tres niveles se compone la etiqueta, de modo que el nombre sale siempre de los datos y no de cómo haya numerado scikit-learn los grupos. Para presentar los resultados, además, los segmentos se ordenan por promedio académico del centroide de mayor a menor y reciben un código corto, de S1 a S4.

4. Resultados: los cuatro segmentos

Con k = 4 el modelo converge a los siguientes grupos (centroides en unidades originales):

Código	N	Edad	Horas	Promedio	Nombre del segmento
S1	3	25,3	12,3	8,46	Jóvenes con mucha dedicación y alto rendimiento
S2	19	51,2	4,1	7,83	Adultos con poca dedicación y alto rendimiento
S3	12	39,8	7,3	5,18	Edad intermedia con dedicación media y rendimiento medio
S4	16	28,2	11,9	2,47	Jóvenes con mucha dedicación y bajo rendimiento

La misma información en unidades estandarizadas muestra de dónde salió cada nombre: el valor indica cuántos desvíos estándar se aparta el centroide del promedio general del curso, y el umbral de clasificación es ±0,50.

Código	Edad (z)	Horas (z)	Promedio (z)	Lectura
S1	-1,29	1,18	1,18	edad baja / dedicación alta / rendimiento alto
S2	1,05	-0,99	0,93	edad alta / dedicación baja / rendimiento alto
S3	0,02	-0,14	-0,13	edad media / dedicación media / rendimiento medio
S4	-1,02	1,06	-1,22	edad baja / dedicación alta / rendimiento bajo

S1 - Jóvenes con mucha dedicación y alto rendimiento (3 estudiantes). Perfil promedio: 25,3 años, 12,3 horas semanales y promedio 8,46. Rangos del grupo: edad de 21 a 29 años, de 8 a 15 horas y promedio de 7,27 a 9,11. Es el único grupo que combina mucha dedicación con buen rendimiento, y también el más chico del modelo: apenas tres estudiantes de entre 21 y 29 años. Son los casos que rompen el patrón general del set, porque estudian bastante y aun así tienen los promedios más altos de todos.

S2 - Adultos con poca dedicación y alto rendimiento (19 estudiantes). Perfil promedio: 51,2 años, 4,1 horas semanales y promedio 7,83. Rangos del grupo: edad de 42 a 60 años, de 2 a 8 horas y promedio de 6,12 a 9,00. Es el segmento más numeroso y el más homogéneo en cuanto a rendimiento: estudiantes maduros que dedican pocas horas semanales y, sin embargo, sostienen promedios altos. En un caso real se interpretaría como gente con experiencia previa o con buenas estrategias de estudio.

S3 - Edad intermedia con dedicación media y rendimiento medio (12 estudiantes). Perfil promedio: 39,8 años, 7,3 horas semanales y promedio 5,18. Rangos del grupo: edad de 34 a 46 años, de 6 a 10 horas y promedio de 4,00 a 6,00. Es el grupo de transición: ni jóvenes ni adultos, con dedicación y rendimiento intermedios. Es el segmento que el algoritmo ubica en el medio del espacio y, por lo tanto, el que tiene fronteras menos nítidas con los demás.

S4 - Jóvenes con mucha dedicación y bajo rendimiento (16 estudiantes). Perfil promedio: 28,2 años, 11,9 horas semanales y promedio 2,47. Rangos del grupo: edad de 22 a 34 años, de 9 a 15 horas y promedio de 1,00 a 4,33. Es el reverso exacto de S1: estudiantes jóvenes que dedican muchas horas y obtienen los promedios más bajos del curso. Es también el grupo mejor definido del modelo según el coeficiente de silueta, porque ocupa una zona del espacio claramente separada del resto.

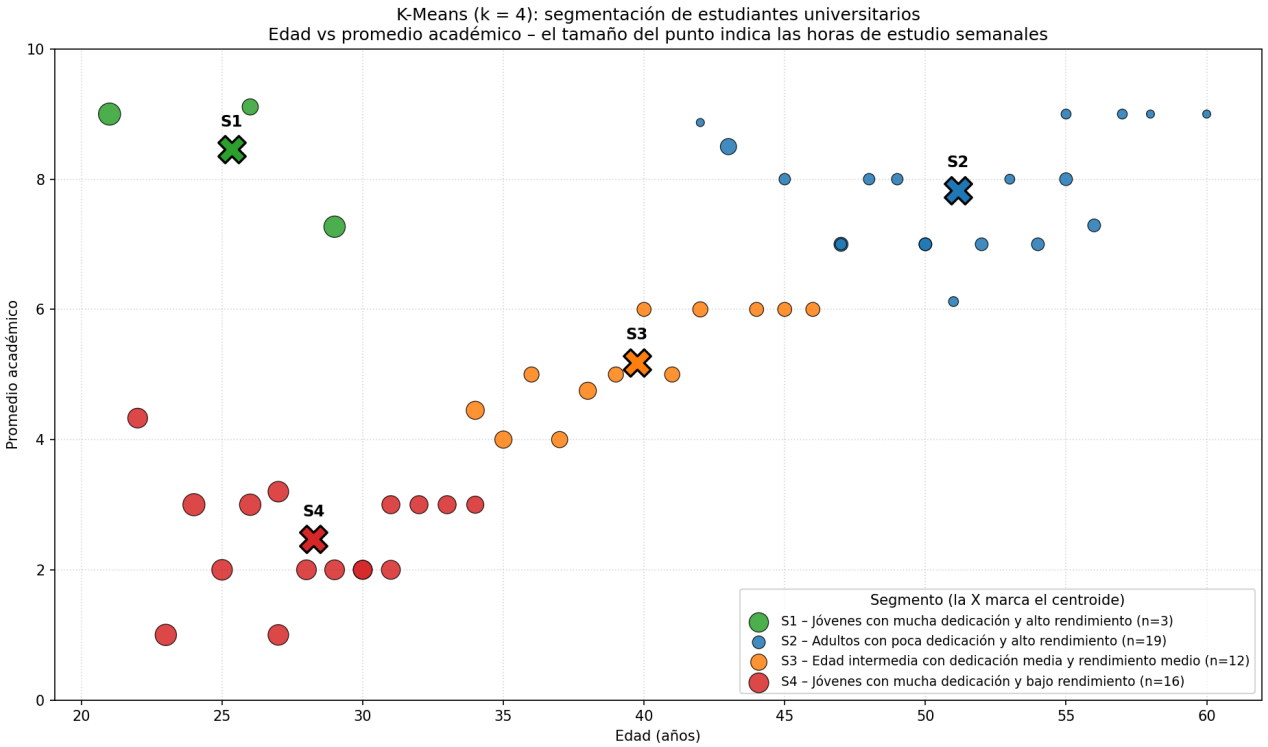
El detalle completo de los 50 estudiantes, ordenado por segmento y edad, es el siguiente:

Seg.	Edad	Horas	Prom.
S1	21	15	9,00
S1	26	8	9,11
S1	29	14	7,27
S2	42	2	8,87
S2	43	8	8,50
S2	45	4	8,00
S2	47	6	7,00
S2	47	4	7,00
S2	48	4	8,00
S2	49	4	8,00
S2	50	5	7,00
S2	50	5	7,00
S2	51	3	6,12
S2	52	5	7,00
S2	53	3	8,00
S2	54	5	7,00
S2	55	3	9,00
S2	55	5	8,00
S2	56	5	7,29
S2	57	3	9,00
S2	58	2	9,00
S2	60	2	9,00
S3	34	10	4,45
S3	35	9	4,00
S3	36	7	5,00

Seg.	Edad	Horas	Prom.
S3	37	8	4,00
S3	38	9	4,75
S3	39	7	5,00
S3	40	6	6,00
S3	41	7	5,00
S3	42	7	6,00
S3	44	6	6,00
S3	45	6	6,00
S3	46	6	6,00
S4	22	12	4,33
S4	23	14	1,00
S4	24	15	3,00
S4	25	13	2,00
S4	26	14	3,00
S4	27	13	3,20
S4	27	13	1,00
S4	28	12	2,00
S4	29	12	2,00
S4	30	11	2,00
S4	30	11	2,00
S4	31	11	2,00
S4	31	10	3,00
S4	32	10	3,00
S4	33	10	3,00
S4	34	9	3,00

5. Visualización en 2D: edad vs promedio académico

El gráfico pedido por la consigna ubica a cada estudiante según su **edad** (eje horizontal) y su **promedio académico** (eje vertical). El color indica el segmento asignado y la X grande marca el centroide de cada grupo. Como el agrupamiento se hizo con tres variables pero el gráfico sólo puede mostrar dos, el **tamaño del punto** representa la tercera: cuanto más grande es el círculo, más horas semanales estudia esa persona.



Segmentación obtenida con K-Means (k = 4) sobre los datos estandarizados. Cada punto es un estudiante; el tamaño indica las horas de estudio semanales.

La lectura del gráfico explica por qué el algoritmo cortó donde cortó. Los puntos se ordenan a lo largo de una diagonal que sube de izquierda a derecha: a mayor edad, mejor promedio. Sobre esa diagonal, S4 (rojo) ocupa el extremo inferior izquierdo -jóvenes con promedios de 1 a 4-, S3 (naranja) la zona central, y S2 (azul) el extremo superior derecho, con los adultos de promedios altos. S1 (verde) queda fuera de la diagonal: son tres jóvenes con promedios de 7,27 a 9,11 que no siguen el patrón del resto y por eso el algoritmo los separa en un grupo propio.

El tamaño de los círculos confirma la relación invertida que mostraba la tabla de correlaciones: los puntos grandes (mucho estudio) se concentran abajo a la izquierda y los chicos (poco estudio) arriba a la derecha. También muestra la frontera entre S2 y S3 como la zona menos nítida del gráfico, con puntos naranjas y azules de promedio 6 a 7 muy próximos entre sí.

6. Calidad del agrupamiento

Para no quedarnos con la impresión visual medimos el resultado con dos indicadores. La **inercia** del modelo es **22,018** sobre una inercia total de 150 en el espacio estandarizado, es decir que los cuatro grupos explican el **85,3 %** de la variabilidad de los datos. El **coeficiente de silueta** va de -1 a 1 y compara, para cada estudiante, qué tan cerca está de su propio grupo frente al grupo vecino más próximo; el valor global es **0,4800**, que indica una estructura razonable pero no fuertemente separada.

Código	Segmento	N	Silueta
S1	Jóvenes con mucha dedicación y alto rendimiento	3	0,3135
S2	Adultos con poca dedicación y alto rendimiento	19	0,4728
S3	Edad intermedia con dedicación media y rendimiento medio	12	0,4451
S4	Jóvenes con mucha dedicación y bajo rendimiento	16	0,5460

El grupo mejor definido es **S4** (silueta 0,5460), porque los jóvenes de bajo rendimiento ocupan una región compacta y alejada del resto. El más débil es **S1** (0,3135): con sólo tres integrantes muy distintos entre sí -uno

estudia 8 horas y otro 15- el grupo es internamente disperso, aunque el algoritmo lo mantenga separado porque no encaja en ninguno de los otros tres.

También comparamos qué hubiera pasado con otros valores de k:

k	Inercia	Varianza explicada	Silueta	Tamaños de los grupos
2	48,219	67,9 %	0,5651	27 - 23
3	33,595	77,6 %	0,4416	18 - 18 - 14
4	**22,018**	**85,3 %**	**0,4800**	**19 - 16 - 12 - 3**
5	16,888	88,7 %	0,4150	17 - 12 - 10 - 8 - 3
6	14,142	90,6 %	0,3759	14 - 10 - 9 - 9 - 5 - 3
7	11,729	92,2 %	0,3984	13 - 12 - 9 - 8 - 5 - 2 - 1

La fila resaltada es la que pide la consigna. La inercia baja siempre que se agregan clusters, así que no sirve por sí sola para elegir k: hay que buscar el «codo», el punto a partir del cual agregar grupos deja de mejorar mucho. Aquí el salto más grande se da al pasar de k = 3 a k = 4 (la inercia cae de 33,6 a 22,0, casi 12 puntos), mientras que de k = 4 a k = 5 la mejora es de apenas 5,1: el codo está justamente en k = 4, lo que respalda el valor pedido.

La silueta, en cambio, es máxima en k = 2 (0,5651) y recién después vuelve a subir en k = 4 (0,4800), que es el segundo mejor valor de toda la serie. Esto significa que, si sólo buscáramos la partición más nítida, los datos se separarían naturalmente en dos bloques -jóvenes de bajo rendimiento por un lado y adultos de alto rendimiento por el otro-. Con k = 4 sacrificamos algo de separación a cambio de una segmentación más informativa, que distingue el grupo intermedio y el de los jóvenes de alto rendimiento. Es un buen ejemplo de que la métrica no decide sola: k = 4 es defendible por el codo de la inercia y por la interpretabilidad de los grupos, aunque no maximice la silueta.

7. Interpretación y limitaciones

El modelo cumple con lo pedido y los cuatro segmentos son interpretables, pero hay varios puntos que conviene señalar antes de sacar conclusiones sobre los estudiantes:

Limitación	Detalle
La relación entre horas y promedio está invertida	La correlación entre horas de estudio y promedio es -0,731: en estos datos, los que más estudian son los que peor rinden. Es un artefacto de la simulación, no un hallazgo. Cualquier conclusión del tipo «estudiar más perjudica el promedio» sería incorrecta: lo único que se puede afirmar es que el set fue generado con ese patrón.
Las variables son casi redundantes	Edad y horas de estudio tienen una correlación de -0,924, casi perfecta y negativa. Un análisis de componentes principales muestra que una sola dimensión explica el 86,0 % de la variabilidad total: aunque el modelo usa tres variables, en la práctica los estudiantes se ordenan a lo largo de un único eje. Eso explica por qué los grupos aparecen alineados en una diagonal en el gráfico.
S1 tiene sólo tres estudiantes	Con 3 integrantes sobre 50, el segmento de jóvenes de alto rendimiento es demasiado chico para sacar conclusiones y su centroide es muy sensible: agregar o quitar un solo estudiante lo movería notablemente. Es la contracara de que K-Means trabaja con medias.
k = 4 viene impuesto por la consigna	La silueta prefiere k = 2 (0,5651 contra 0,4800). Fijar k de antemano es una limitación propia de K-Means: el algoritmo siempre devuelve exactamente los grupos que se le piden, incluso si los datos no tienen esa estructura.
Supuestos del algoritmo	K-Means asume grupos de forma esférica y de tamaño similar. Aquí los tamaños van de 3 a 19 estudiantes, y la frontera entre S2 y S3 es una línea recta trazada a mitad de camino entre dos centroides, no un límite que exista realmente en los datos.
Son datos simulados	El set no proviene de una institución real: no hay carrera, año de cursada, situación laboral ni cantidad de materias aprobadas. Un trabajo real necesitaría esas variables para que los segmentos tengan utilidad práctica.

Mejoras propuestas. La primera sería revisar la generación de los datos, para que la relación entre dedicación y rendimiento sea realista antes de interpretar nada. La segunda, elegir k con criterio -comparando codo y silueta, como se hizo en la sección 6- en lugar de fijarlo de entrada. También convendría agregar variables que aporten información nueva en vez de repetir el mismo eje (por ejemplo materias aprobadas, asistencia o si el estudiante trabaja), y probar métodos alternativos: un agrupamiento jerárquico mostraría cómo se van uniendo los grupos sin tener que fijar k, y uno basado en densidad como DBSCAN trataría mejor a los casos atípicos como los tres estudiantes de S1.

8. Conclusión

El programa cumple los cinco puntos de la consigna: estandariza las tres variables con `StandardScaler`, agrupa a los 50 estudiantes en 4 segmentos con K-Means, les asigna etiquetas interpretables derivadas de los centroides, muestra a qué grupo pertenece cada estudiante y visualiza el resultado en un gráfico 2D de edad contra promedio académico.

Los cuatro segmentos encontrados son: **S2**, adultos de alto rendimiento con poca dedicación (19 estudiantes, el grupo más numeroso); **S4**, jóvenes de mucha dedicación y bajo rendimiento (16); **S3**, un grupo intermedio en las tres variables (12); y **S1**, un pequeño núcleo de jóvenes de alto rendimiento (3). El modelo explica el 85,3 % de la variabilidad con una silueta de 0,4800.

La conclusión metodológica más importante del trabajo es el valor de la estandarización. Es el único paso que separa una segmentación de tres variables de un simple ordenamiento por edad: sin estandarizar, la edad concentraba el 85,4 % del peso en la distancia y los grupos resultantes eran cuatro franjas etarias que ignoraban por completo el rendimiento académico. La segunda conclusión es que el algoritmo describe los datos que recibe, no la realidad: la relación invertida entre horas de estudio y promedio que aparece en los segmentos es una propiedad del set simulado, y leerla como un hallazgo sobre los estudiantes sería el error más grave que se podría cometer con este modelo.